Aprendizaje automático y ciencia de datos: Soluciones a los ejercicios 3.1–3.18

Tu nombre

7 de octubre de 2026

Resumen

Este informe responde a los dieciocho ejercicios sobre aprendizaje automático y ciencia de datos. Las preguntas conceptuales se responden a partir de definiciones estándar, y las computacionales (reglas de asociación, distancias euclidianas, árbol de decisión) se resuelven paso a paso.

Contenido

1 Introducción 3

2 Método 3

2.1 Preguntas conceptuales 3

2.2 Minería de reglas de asociación (ejercicios 3.9 y 3.10) 3

2.3 Distancia euclidiana (ejercicios 3.15 y 3.16) 3

2.4 Árbol de decisión (ejercicio 3.11) 3

3 Resultados 3

3.1 Ejercicio 3.1: Tipos de aprendizaje automático 3

3.2 Ejercicio 3.2: Técnicas principales del aprendizaje supervisado 4

3.3 Ejercicio 3.3: Aprendizaje supervisado frente a no supervisado 4

3.4 Ejercicio 3.4: Elección de una técnica para los datos de salud 4

3.5 Ejercicio 3.5: Elección de una técnica para los datos de género y edad 4

3.6 Ejercicio 3.6: Datos etiquetados y sin etiquetar 5

3.7 Ejercicio 3.7: Clasificación de algoritmos 5

3.8 Ejercicio 3.8: Pruebas A/B 5

3.9 Ejercicio 3.9: Reglas de asociación 6

3.10 Ejercicio 3.10: Soporte, confianza y elevación 7

3.11 Ejercicio 3.11: Árbol de decisión para la política de promociones 7

3.12 Ejercicio 3.12: Ventajas y desventajas de los árboles de decisión 8

3.13 Ejercicio 3.13: Enfoques del análisis de conglomerados 8

3.14 Ejercicio 3.14: Técnicas de agrupamiento jerárquico 9

3.15 Ejercicio 3.15: Distancia euclidiana mínima 9

3.16 Ejercicio 3.16: Distancia euclidiana máxima 9

3.17 Ejercicio 3.17: Pasos del proceso de reconocimiento de patrones 9

3.18 Ejercicio 3.18: Datos de entrenamiento frente a datos de prueba 10

4 Discusión 10

5 Conclusión 10

1 Introducción

Los ejercicios abarcan los tipos de aprendizaje automático, las técnicas supervisadas y no supervisadas, las pruebas A/B, la minería de reglas de asociación, los árboles de decisión, el análisis de conglomerados, el reconocimiento de patrones y el uso de datos de entrenamiento y de prueba. La sección 2 describe cómo se abordó cada grupo de ejercicios, la sección 3 presenta las respuestas, y las secciones 4 y 5 las discuten y resumen.

2 Método

2.1 Preguntas conceptuales

Los ejercicios 3.1–3.3, 3.6, 3.8, 3.12–3.14, 3.17 y 3.18 se respondieron definiendo cada concepto y comparándolo con otros relacionados. Los ejercicios 3.4, 3.5 y 3.7 se resolvieron comprobando si los datos contienen una columna objetivo (etiqueta) y emparejando después cada algoritmo con su paradigma de aprendizaje.

2.2 Minería de reglas de asociación (ejercicios 3.9 y 3.10)

La tabla de transacciones se analizó con el principio Apriori: un conjunto de artículos solo puede ser frecuente si todos sus subconjuntos son frecuentes. Sea N = 10 el número de transacciones y σ(X) el número de transacciones que contienen el conjunto X. Para una regla A ⇒ B:

$$\text{soporte}(A \Rightarrow B) = \sigma(A \cup B) / N, \quad (1)$$

$$\text{confianza}(A \Rightarrow B) = \sigma(A \cup B) / \sigma(A), \quad (2)$$

$$\text{elevación}(A \Rightarrow B) = \text{confianza}(A \Rightarrow B) / \text{soporte}(B) = N \cdot \sigma(A \cup B) / (\sigma(A) \cdot \sigma(B)). \quad (3)$$

El ejercicio no da umbrales, por lo que se eligieron los siguientes: soporte mínimo = 0,3 (al menos 3 de 10 transacciones) y confianza mínima = 0,6. Los artículos «Yoghurt» y «Yogurt» (transacción 7) se trataron como el mismo artículo.

2.3 Distancia euclidiana (ejercicios 3.15 y 3.16)

Para dos puntos $p = (x_1, x_2)$ y $q = (y_1, y_2)$,

$$d(p, q) = \sqrt{((x_1 - y_1)^2 + (x_2 - y_2)^2)}. \quad (4)$$

Se consideraron todas las distancias entre pares y se seleccionó el par con la distancia menor (3.15) o mayor (3.16).

2.4 Árbol de decisión (ejercicio 3.11)

Las cuatro reglas de promoción se agruparon según la única condición que comprueban (la ganancia comparada con el 30 %), que pasa a ser el nodo raíz. Cada resultado se convierte en una hoja.

3 Resultados

3.1 Ejercicio 3.1: Tipos de aprendizaje automático

- **Aprendizaje supervisado:** el modelo aprende de ejemplos etiquetados (entradas emparejadas con salidas conocidas) y luego predice la salida para entradas nuevas. Ejemplos: detección de correo no deseado, predicción del precio de viviendas.

- **Aprendizaje no supervisado:** el modelo recibe datos sin etiquetar y descubre por sí mismo su estructura, como grupos, asociaciones o representaciones de menor dimensión. Ejemplos: segmentación de clientes, análisis de la cesta de la compra.
- **Aprendizaje por refuerzo:** un agente interactúa con un entorno, realiza acciones y recibe recompensas o penalizaciones. Aprende una política que maximiza la recompensa acumulada. Ejemplos: juegos, control de robots.

3.2 Ejercicio 3.2: Técnicas principales del aprendizaje supervisado

- **Clasificación:** la salida es una categoría discreta (por ejemplo, sano/enfermo o spam/no spam). El modelo aprende una frontera de decisión entre clases. Algoritmos típicos: regresión logística, k vecinos más cercanos, máquinas de vectores de soporte, Naïve Bayes, árboles de decisión.
- **Regresión:** la salida es un valor numérico continuo (por ejemplo, precio o temperatura). El modelo aprende una función que asigna las entradas a ese valor. Algoritmos típicos: regresión lineal, regresión polinómica, árboles de regresión.

3.3 Ejercicio 3.3: Aprendizaje supervisado frente a no supervisado

Diferencias

1. El aprendizaje supervisado usa datos etiquetados; el no supervisado usa datos sin etiquetar.
2. El aprendizaje supervisado busca predecir un objetivo conocido (clasificación o regresión); el no supervisado busca descubrir estructura oculta (agrupamiento, asociación, reducción de dimensionalidad).
3. Los modelos supervisados se evalúan frente a respuestas conocidas (exactitud, RMSE, etc.); los resultados no supervisados carecen de verdad de referencia y se juzgan con medidas internas (por ejemplo, el coeficiente de silueta) o por interpretación.

Similitudes

1. Ambos aprenden patrones a partir de los datos en lugar de reglas programadas explícitamente.
2. Ambos dependen de la calidad de los datos y requieren preprocesamiento (limpieza, escalado, selección de características).
3. Ambos intentan generalizar a datos nuevos no vistos y pueden sobreajustarse si el modelo es demasiado complejo.

3.4 Ejercicio 3.4: Elección de una técnica para los datos de salud

La tabla tiene las columnas Salud, Género y Edad. La columna Salud (Sano/Enfermo) es un resultado conocido para cada fila, por lo que los datos están etiquetados. El **aprendizaje supervisado (clasificación)** es adecuado: Salud es el objetivo, y Género y Edad son las características de entrada. El clasificador entrenado podría predecir el estado de salud de una persona nueva.

3.5 Ejercicio 3.5: Elección de una técnica para los datos de género y edad

La tabla contiene solo Género y Edad, sin columna objetivo. Los datos están sin etiquetar, por lo que el **aprendizaje no supervisado** (por ejemplo, el agrupamiento) es adecuado para encontrar grupos naturales de personas con características similares.

3.6 Ejercicio 3.6: Datos etiquetados y sin etiquetar

Los **datos etiquetados** son observaciones que vienen con una salida conocida (etiqueta u objetivo), como una imagen marcada como «gato» o un paciente marcado como «enfermo». Los **datos sin etiquetar** contienen solo características de entrada y ninguna salida conocida.

Para identificar de qué tipo es un conjunto de datos, se comprueba si alguna columna es un resultado designado que las demás columnas deben explicar o predecir (una clase, una categoría o un objetivo numérico). Si existe esa columna, los datos están etiquetados; si todas las columnas son simples características descriptivas, los datos están sin etiquetar.

3.7 Ejercicio 3.7: Clasificación de algoritmos

Supervisado	No supervisado	Por refuerzo
Máquinas de vectores de soporte	K-Means	Q-learning
K vecinos más cercanos	Agrupamiento jerárquico	Diferencia temporal (TD)
Regresión lineal	Análisis de componentes principales	
Regresión logística	t-SNE	
Naïve Bayes	Redes antagónicas profundas*	

Tabla 1: Clasificación de los algoritmos listados.

*Las redes antagónicas profundas (GAN) aprenden a generar datos a partir de ejemplos sin etiquetar, por lo que normalmente se sitúan en el aprendizaje no supervisado.

3.8 Ejercicio 3.8: Pruebas A/B

Definición. Una prueba A/B es un experimento controlado que compara dos versiones de algo (A, el control, y B, la variante) exponiendo a grupos de usuarios asignados al azar a cada versión y midiendo cuál rinde mejor en una métrica elegida.

Planificación.

1. Definir el objetivo y una métrica medible (por ejemplo, la tasa de conversión o la tasa de clics).
2. Plantear la hipótesis (por ejemplo, «el nuevo color del botón aumenta los registros»).
3. Crear las variantes, cambiando un solo elemento a la vez.
4. Determinar el tamaño de muestra y la duración de la prueba necesarios para lograr potencia estadística.
5. Dividir aleatoriamente a los usuarios en el grupo A y el grupo B.
6. Ejecutar ambas versiones al mismo tiempo y recopilar datos.
7. Analizar los resultados con una prueba estadística (prueba t, chi cuadrado, valor p, intervalo de confianza) y decidir si se adopta la variante.

Aplicaciones. Sitios web y páginas de destino, interfaces de aplicaciones móviles, asuntos y campañas de correo electrónico, anuncios en línea, precios y promociones, algoritmos de búsqueda y recomendación, y nuevas funciones de producto.

3.9 Ejercicio 3.9: Reglas de asociación

Recuentos de artículos (sobre N = 10 transacciones): Huevos 6, Pollo 6, Leche 5, Mantequilla 5, Arroz 5, Queso 4, Yoghurt 4, Res 3, Aceite 3, Aceitunas 3, Miel 2, Ketchup 2, Mermelada 1. Los artículos con soporte inferior a 0,3 (Miel, Ketchup, Mermelada) se descartan.

Conjunto frecuente	σ	Soporte
{Leche, Huevos}	3	0,3
{Leche, Queso}	3	0,3
{Leche, Pollo}	3	0,3
{Mantequilla, Huevos}	3	0,3
{Mantequilla, Queso}	3	0,3
{Mantequilla, Pollo}	3	0,3
{Huevos, Aceite}	3	0,3
{Huevos, Aceitunas}	3	0,3
{Queso, Yoghurt}	3	0,3
{Pollo, Arroz}	3	0,3
{Res, Arroz}	3	0,3
{Aceite, Aceitunas}	3	0,3
{Huevos, Aceite, Aceitunas}	3	0,3

Tabla 2: Conjuntos frecuentes de tamaño al menos 2 (soporte mínimo 0,3). El par {Huevos, Pollo} también tiene soporte 0,3, pero sus dos reglas tienen confianza 0,5 < 0,6 y se rechazan.

Reglas que cumplen soporte mínimo 0,3 y confianza mínima 0,6:

- Leche ⇒ Huevos; Leche ⇒ Queso; Queso ⇒ Leche; Leche ⇒ Pollo
- Mantequilla ⇒ Huevos; Mantequilla ⇒ Queso; Queso ⇒ Mantequilla; Mantequilla ⇒ Pollo
- Aceite ⇒ Huevos; Aceitunas ⇒ Huevos; Aceite ⇒ Aceitunas; Aceitunas ⇒ Aceite
- Queso ⇒ Yoghurt; Yoghurt ⇒ Queso
- Arroz ⇒ Pollo; Res ⇒ Arroz; Arroz ⇒ Res
- {Aceite, Aceitunas} ⇒ Huevos; {Huevos, Aceite} ⇒ Aceitunas; {Huevos, Aceitunas} ⇒ Aceite
- Aceite ⇒ {Huevos, Aceitunas}; Aceitunas ⇒ {Huevos, Aceite}

3.10 Ejercicio 3.10: Soporte, confianza y elevación

Regla	Soporte	Confianza	Elevación
Leche ⇒ Huevos	0,30	0,60	1,00
Leche ⇒ Queso	0,30	0,60	1,50
Queso ⇒ Leche	0,30	0,75	1,50
Leche ⇒ Pollo	0,30	0,60	1,00
Mantequilla ⇒ Huevos	0,30	0,60	1,00
Mantequilla ⇒ Queso	0,30	0,60	1,50
Queso ⇒ Mantequilla	0,30	0,75	1,50
Mantequilla ⇒ Pollo	0,30	0,60	1,00
Aceite ⇒ Huevos	0,30	1,00	1,67
Aceitunas ⇒ Huevos	0,30	1,00	1,67
Queso ⇒ Yoghurt	0,30	0,75	1,88
Yoghurt ⇒ Queso	0,30	0,75	1,88
Arroz ⇒ Pollo	0,30	0,60	1,00
Res ⇒ Arroz	0,30	1,00	2,00
Arroz ⇒ Res	0,30	0,60	2,00
Aceite ⇒ Aceitunas	0,30	1,00	3,33
Aceitunas ⇒ Aceite	0,30	1,00	3,33
{Aceite, Aceitunas} ⇒ Huevos	0,30	1,00	1,67
{Huevos, Aceite} ⇒ Aceitunas	0,30	1,00	3,33
{Huevos, Aceitunas} ⇒ Aceite	0,30	1,00	3,33
Aceite ⇒ {Huevos, Aceitunas}	0,30	1,00	3,33
Aceitunas ⇒ {Huevos, Aceite}	0,30	1,00	3,33

Tabla 3: Soporte, confianza y elevación de las reglas seleccionadas.

Ejemplo resuelto: para Queso ⇒ Yoghurt, σ(Queso ∪ Yoghurt) = 3, σ(Queso) = 4 y σ(Yoghurt) = 4, por lo que soporte = 3/10 = 0,3, confianza = 3/4 = 0,75 y elevación = (10·3)/(4·4) = 1,875 ≈ 1,88.

3.11 Ejercicio 3.11: Árbol de decisión para la política de promociones

Las cuatro reglas comprueban la misma condición, ganancia ≥ 30 %, y dan el mismo resultado para descuentos y regalos. El árbol resultante se muestra en la figura 1.

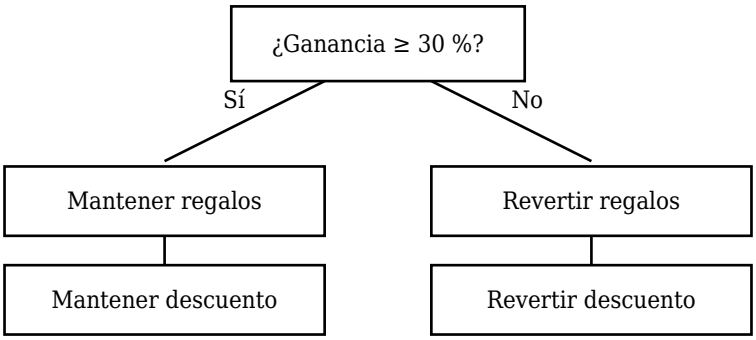


Figura 1: Árbol de decisión para la política de promociones.

3.12 Ejercicio 3.12: Ventajas y desventajas de los árboles de decisión

Ventajas

- Fáciles de entender, visualizar e interpretar.
- Manejan datos numéricos y categóricos con poca preparación de los datos (no necesitan escalado).
- Realizan selección implícita de características y captan relaciones no lineales.
- Rápidos para predecir.

Desventajas

- Propensos al sobreajuste, sobre todo los árboles profundos, por lo que hace falta podarlos.
- Inestables: pequeños cambios en los datos pueden producir un árbol muy distinto.
- La división voraz no garantiza un árbol globalmente óptimo.
- Sesgados hacia las características con muchos niveles y hacia las clases dominantes en datos desbalanceados.
- Menos precisos que los conjuntos de modelos (bosques aleatorios, boosting) en muchos problemas.

3.13 Ejercicio 3.13: Enfoques del análisis de conglomerados

Hay cinco enfoques principales:

1. **Métodos de partición:** dividen los datos en k conglomerados disjuntos optimizando un criterio (por ejemplo, K-Means, K-Medoids).
2. **Métodos jerárquicos:** construyen un árbol de conglomerados anidados (dendrograma), de abajo arriba o de arriba abajo.
3. **Métodos basados en densidad:** definen los conglomerados como regiones densas separadas por regiones poco densas; encuentran conglomerados de forma arbitraria y detectan ruido (por ejemplo, DBSCAN).
4. **Métodos basados en cuadrícula:** dividen el espacio de datos en una cuadrícula finita de celdas y agrupan las celdas, lo que es rápido en conjuntos de datos grandes (por ejemplo, STING).
5. **Métodos basados en modelos:** suponen que los datos provienen de una mezcla de distribuciones estadísticas y ajustan el modelo (por ejemplo, modelos de mezclas gaussianas).

3.14 Ejercicio 3.14: Técnicas de agrupamiento jerárquico

Hay dos técnicas:

- **Aglomerativa (de abajo arriba):** cada objeto comienza como su propio conglomerado, y los dos conglomerados más cercanos se fusionan repetidamente hasta que queda uno solo. La cercanía se mide con una regla de enlace (simple, completo, promedio, Ward).
- **Divisiva (de arriba abajo):** todos los objetos comienzan en un conglomerado, que se divide recursivamente en conglomerados más pequeños hasta que cada objeto queda solo o se cumple un criterio de parada.

3.15 Ejercicio 3.15: Distancia euclidiana mínima

Las distancias más pequeñas entre pares son:

Par	Distancia
A(8,2) – J(8,1)	$\sqrt{(0^2 + 1^2)} = 1$
A(8,2) – H(7,3)	$\sqrt{2} \approx 1{,}41$
D(6,4) – H(7,3)	$\sqrt{2} \approx 1{,}41$
C(3,3) – G(3,1)	2

La distancia mínima es 1, alcanzada únicamente por los objetos A y J.

3.16 Ejercicio 3.16: Distancia euclidiana máxima

Las distancias más grandes entre pares son:

Par	Distancia
E(3,1) – I(1,9)	$\sqrt{(2^2 + 8^2)} = \sqrt{68} \approx 8{,}25$
F(5,2) – I(1,9)	$\sqrt{(4^2 + 7^2)} = \sqrt{65} \approx 8{,}06$
A(1,1) – I(1,9)	8
F(5,2) – G(1,8)	$\sqrt{52} \approx 7{,}21$

La distancia máxima es $\sqrt{68} \approx 8{,}25$, alcanzada únicamente por los objetos E e I. (Los objetos C y D son idénticos, por lo que su distancia mutua es 0.)

3.17 Ejercicio 3.17: Pasos del proceso de reconocimiento de patrones

1. **Adquisición de datos:** se recogen datos en bruto con sensores, cámaras, micrófonos, bases de datos o encuestas, y se convierten a forma digital. La calidad y la representatividad de los datos limitan todo lo que sigue.
2. **Preprocesamiento de datos:** los datos se limpian y se preparan eliminando ruido, tratando valores faltantes y atípicos, normalizando o escalando, y segmentando la señal o la imagen.
3. **Extracción/selección de características:** se calculan medidas informativas y discriminantes a partir de los datos preprocesados (extracción), y se conservan las más relevantes descartando las redundantes (selección). Esto reduce la dimensionalidad y mejora la precisión.
4. **Clasificación:** un modelo entrenado con las características asigna cada patrón a una clase (o predice un valor), usando algoritmos como k-NN, SVM, árboles de decisión o redes neuronales.

5 **Posprocesamiento:** la salida del clasificador se evalúa y se refina, por ejemplo mediante umbrales de confianza, rechazo de resultados inciertos, combinación de clasificadores, reglas de contexto y medición del rendimiento, antes de actuar según la decisión.

3.18 Ejercicio 3.18: Datos de entrenamiento frente a datos de prueba

Los **datos de entrenamiento** son la parte del conjunto de datos que se usa para ajustar el modelo: el algoritmo aprende de ellos sus parámetros y patrones. Los **datos de prueba** son una parte separada que se reserva y nunca se usa durante el entrenamiento; se emplean después para medir qué tan bien generaliza el modelo a datos no vistos. Evaluar con los datos de entrenamiento daría una estimación demasiado optimista debido al sobreajuste. Una división habitual es del 70–80 % para entrenamiento y del 20–30 % para prueba.

4 Discusión

La distinción entre datos etiquetados y sin etiquetar (ejercicios 3.4–3.7) es la clave para elegir entre métodos supervisados y no supervisados. En el análisis de reglas de asociación, las relaciones más fuertes se dieron entre Aceite, Aceitunas y Huevos (elevación 3,33 para los pares y tríos que incluyen Aceite y Aceitunas) y entre Res y Arroz (elevación 2,0). Las reglas con elevación 1,0, como Leche ⇒ Huevos, superan el umbral de confianza, pero solo reflejan la popularidad del artículo consecuente, por lo que no son informativas. Los resultados dependen de los umbrales elegidos (0,3 y 0,6) y de la pequeña muestra de diez transacciones, por lo que deben tomarse como ilustrativos. En los ejercicios de distancia, un solo par alcanzó el mínimo y el máximo, por lo que no hubo que informar empates.

5 Conclusión

Se respondieron los dieciocho ejercicios. Los datos etiquetados exigen aprendizaje supervisado y los datos sin etiquetar, aprendizaje no supervisado; las reglas de asociación se extrajeron con Apriori y se evaluaron mediante soporte, confianza y elevación; la política de promociones se reduce a un árbol de decisión de una sola división; y los pares de objetos más cercano y más lejano son A–J y E–I, respectivamente.