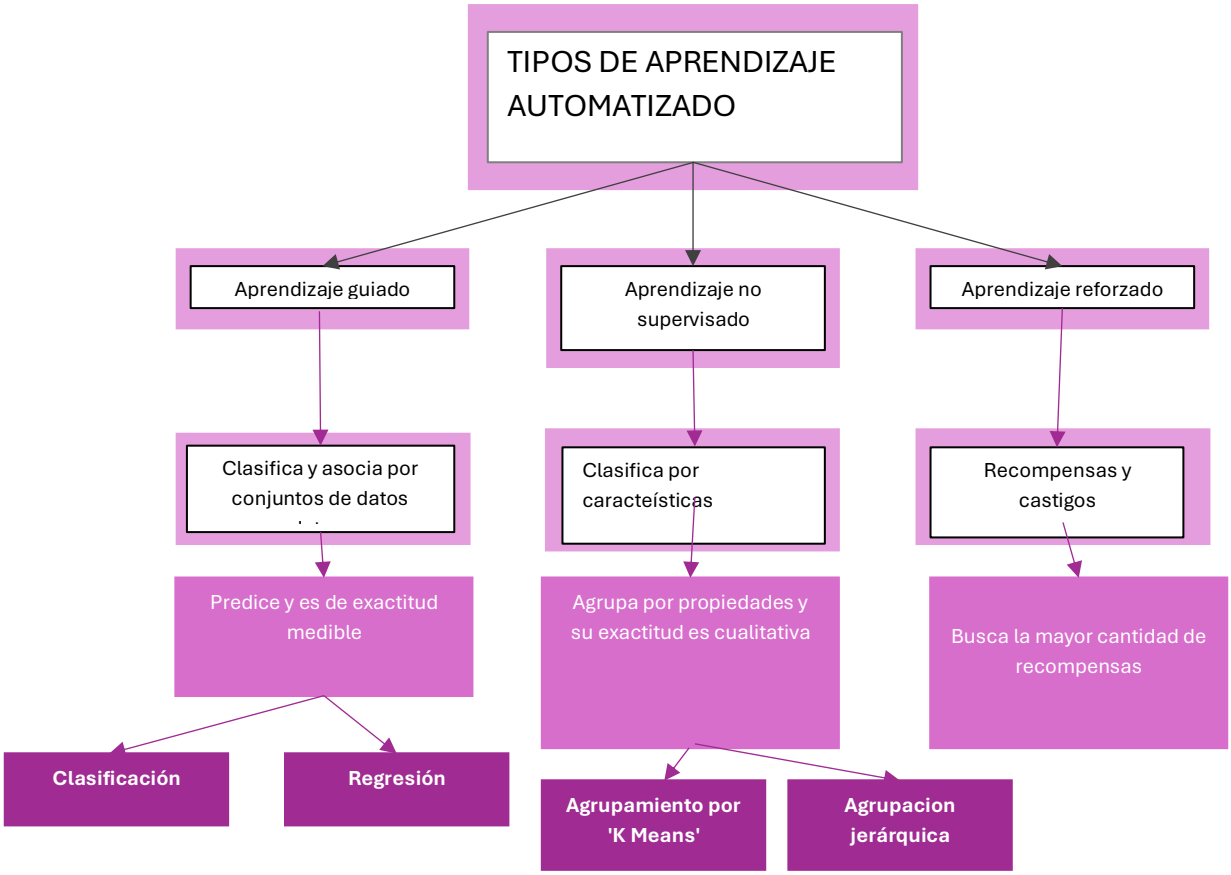
# Técnicas más usadas en la aplicación de la ciencia de datos.

## Ejercicio 3.1

¿Cuáles son los tres tipos de aprendizaje-automatizado (machine learning)?




## Ejercicio 3.2

### ¿Cuáles son las dos principales técnicas de aprendizaje guiado?

Ambas técnicas funcionan por **variables dependientes e independientes** que el modelo utiliza para identificar el mapeo, así, emplea el mapa obtenido del conjunto de datos previamente cargado.

- **Clasificación:**
  Clasifica los datos desconocidos (ejemplo: clasificación de mujer y hombres, spam o no spam).
- **Regresión:**

Intenta encontrar el valor de la variable dependiente a partir de variables independientes (dadas en valores reales).

## Ejercicio 3.3

¿Cuáles son las similitudes y diferencias entre el aprendizaje guiado y no guiado?

| **Guiado** | **No Guiado** |
|---|---|
| Datos preclasificados. | Datos no clasificados. |
| Busca predecir eventos/ocurrencia. | Agrupa por propiedades |
| Su precisión es medible. | Su evaluación es cualitativa. |

## Ejercicio 3.4

Considerando los datos dados, entre técnicas de aprendizaje supervisado y no supervisado: ¿cuál utilizarías para estos datos y por qué?

| Health | Gender | Age |
|---|---|---|
| Healthy | Male | 42 |
| Healthy | Female | 49 |
| Healthy | Male | 66 |
| Healthy | Female | 55 |
| Healthy | Female | 49 |
| Sick | Male | 31 |
| Sick | Female | 53 |
| Sick | Female | 79 |
| Sick | Male | 53 |
| Sick | Male | 31 |

Para este ejercicio podemos identificar que cada columna puede tener un criterio estricto (Salud: saludable / no saludable; Género: Mujer / Hombre; Edad: +50 / -50. Por lo que el modelo más adecuado sería el aprendizaje guiado, especialmente el de clasificación.

## Ejercicio 3.5

Considerando los datos dados, entre técnicas de aprendizaje supervisado y no supervisado: ¿cuál utilizarías para estos datos y por qué?

| Gender | Age |
|---|---|
| Male | 70 |
| Female | 66 |
| Male | 38 |
| Female | 40 |
| Female | 64 |
| Male | 42 |
| Female | 67 |
| Female | 72 |
| Male | 62 |
| Male | 66 |

En este caso, el aprendizaje supervisado sería una mejor opción ya que podemos identificar grupos o patrones sin tener un objetivo definido.

## Ejercicio 3.6

### Explica los términos “datos etiquetados/clasificados” y “datos no etiquetados/no clasificados”

Puedes diferenciar los datos calificados de los no clasificados revisando si el conjunto de datos dado contiene una variable objetiva que indique cual es el producto que se busca aprender o predecir con el modelo.

**Datos clasificados:** incluye criterios de entrada y salida que el modelo puede predecir.

**Datos no clasificados:** Los datos tienen características, pero no contiene criterios de salida.

## Ejercicio 3.7

Considere los nombres de los algoritmos de aprendizaje automático que se presentan a continuación; deberá clasificarlos en las categorías de aprendizaje supervisado, no supervisado y reforzado.

• *Máquinas de vectores de soporte*

Aprendizaje guiado.

• *K-Means más cercanos*

Aprendizaje guiado.

• *K-Means*

Aprendizaje no supervisado.

• *Q-learning*

Aprendizaje reforzado.

• *Diferencia temporal (TD)*

Aprendizaje reforzado.

• *Redes adversarias profundas*

Aprendizaje reforzado.

• *Agrupamiento jerárquico*

Aprendizaje no supervisado.

• *Análisis de componentes principales*

Aprendizaje no supervisado.

| **Aprendizaje guiado** | **Aprendizaje no supervisado** | **Aprendizaje reforzado** |
|---|---|---|
| **Máquinas de soporte de vectores** | K-Means | Q-learning |
| **Regresión linear** | Grupos jerárquicos | Diferencia temportal (TD) |
| **Regresión lógica** | Componente principal de analisis | Redes adverasarias profundas |
| **Naíve Bayes** | Incrustación de vecinos estocásticos distribuida en t. | |
| **K-means más cercanos** | (t-SNE) | |

## Ejercicio 3.8

### ¿A qué se refiere el término AB testing? ¿Como se planea? ¿qué tipo de aplicaciones pueden ser probadas usando esta técnica?

Este método funciona comparando A con B, por eso su nombre “AB Testing”

Toma dos conceptos y los analiza.

Para planearlo:

1. Identificar qué, como y cuando probar.
2. Identifica las variables a considerar,
3. Enlista los posibles resultados (considera todas las posibilidades para cada opción).
4. La opción más prometedora debe ser seleccionada.

Este método es de gran utilidad cuando se quiere evaluar la preferencia hacia alguna variable u opción. Existen diferentes variables a considerar dependiendo del contexto en el que sea aplicado. Por ejemplo:

**Periódicos**

- **Encabezados**
- **Cuerpo de texto**
- **Formato del cuerpo**
- **Imágenes**

## Ejercicio 3.9

### Usa la siguiente tabla y encuentra sus las reglas de asociación.

| TID | Items |
|---|---|
| 1 | Milk, Butter, Eggs, Cheese, Yoghurt |
| 2 | Butter, Eggs, Chicken, Beef, Rice |
| 3 | Chicken, Beef, Rice, Milk |
| 4 | Butter, Chicken, Jam, Honey, Ketchup |
| 5 | Oil, Olives, Milk, Eggs, Honey |
| 6 | Ketchup, Oil, Olives, Eggs, Rice |
| 7 | Yogurt, Chicken, Oil, Olives, Eggs |
| 8 | Cheese, Yoghurt, Chicken, Milk, Rice |
| 9 | Cheese, Yoghurt, Beef, Rice, Butter |
| 10 | Milk, Cheese, Eggs, Chicken, Butter |

Sea 10 el total de transacciones en la lista:

Consideramos un soporte mínimo del 30% (que el conjunto este presente en al menos 3 transacciones).

## Ejercicio 3.10

Considera los datos proporcionados en el Ejercicio 3.9 y calcula el soporte (support), la confianza (confidence) y la elevación (lift).

Para desarrollo del ejercicio 3.10 y 3.9 en el link: Book.xlsx

## Ejercicio 3.11

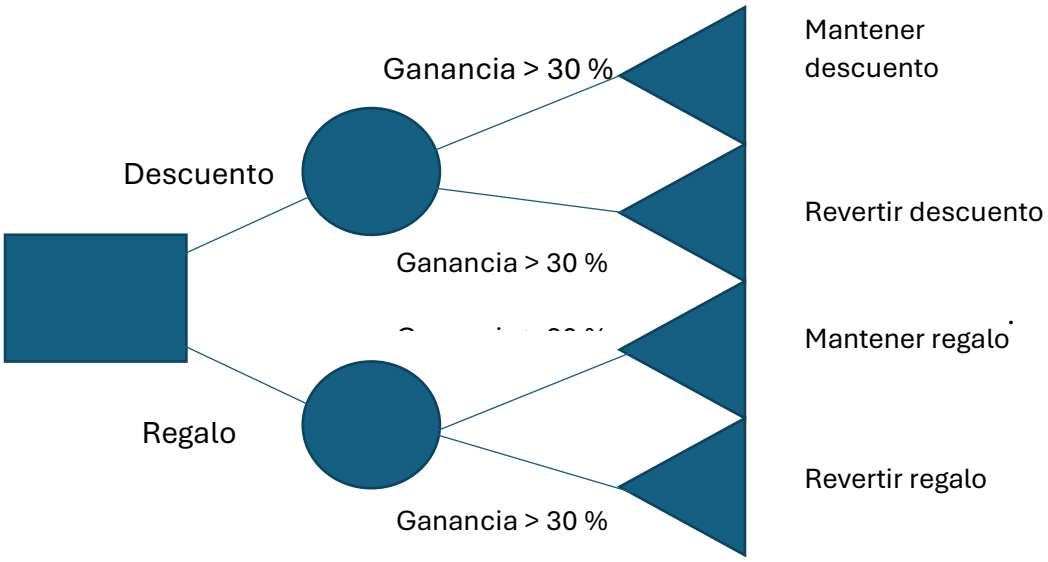
Una compañía tiene una política de promoción donde los regalos y descuentos son premiados para incrementar las ganancias. Considera las siguientes reglas y construye un árbol de diseño.

*Si la ganancia es mayor o igual al 30 %, conservar el descuento.*

*Si la ganancia es menor al 30 %, revertir el descuento.*

*Si la ganancia es mayor o igual al 30 %, conservar los regalos.*

*Si la ganancia es menor al 30 %, revertir los regalos.*



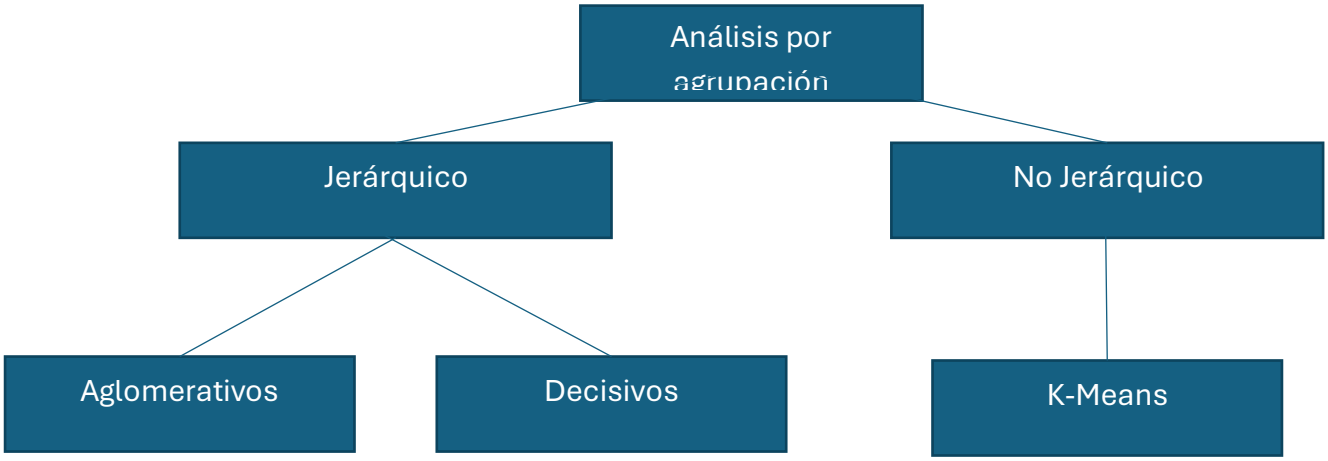

## Ejercicio 3.12

¿Cuáles son las ventajas y desventajas del árbol de decisión?

| **Ventajas** | **Desventajas** |
|---|---|
| Fácil de entender | No son buenos para valores contínuos |
| Dan análisis completos | El mismo sub-árbol puede estar repetido en distintos caminos |
| Son flexibles a comparación de otros métodos | Pequeños cambios pueden conducir a cambios significativos en la estructura del árbol |
| Da mapas completos de eventos conectados | |
| Fácil empleo | |
| Puede ayudar al problema de múltiple clasificación | |
| Oportuniddad de cuantificar las posibles decisiones | |

## Ejercicio 3.13

¿Cuántos enfoques tenemos para el análisis de clústeres?




## Ejercicio 3.14

¿Cuántas técnicas de clústering hay en el análisis jerárquico de clústeres?

| Método de aglomeración | Método de decisión |
|---|---|
| Cada objeto forma su clúster. Luego, los clústeres similares son agrupados hasta que tengamos clústeres clave grandes. | Los clústeres clasifican a los objetos. Empezamos con un solo clúster al que se le asignaran todos los objetos, hasta que cada objeto tenga su clúster. |

Ejercicio 3.15

Con base en la siguiente tabla, identifica dos objetos que tengan la menor distancia Euclidiana.

| | X1 | X2 |
|---|---|---|
| A | 8 | 2 |
| B | 1 | 8 |
| C | 3 | 3 |
| D | 6 | 4 |
| E | 3 | 7 |
| F | 8 | 8 |
| G | 3 | 1 |
| H | 7 | 3 |
| I | 6 | 9 |
| J | 8 | 1 |

La distancia menor se encuentra entre A y J. Ver excel adjunto o de click en el siguiente enlace

## Ejercicio 3.16

### Considerando la siguiente tabla, encuentra dos objetos con la mayor distancia Euclidiana.

| | X1 | X2 |
|---|---|---|
| A | 1 | 1 |
| B | 6 | 5 |
| C | 3 | 3 |
| D | 3 | 3 |
| E | 3 | 1 |
| F | 5 | 2 |
| G | 1 | 8 |
| H | 1 | 3 |
| I | 1 | 9 |
| J | 4 | 3 |

La distancia menor se encuentra entre B y J, ya que es casi 10. Ver excel adjunto o de click en el siguiente enlace Book.xlsx

## Ejercicio 3.17

### Los pasos del proceso para reconocimiento de patrones se enlistan a continuación. Da detalles de cada uno.

*Adquisición*

Se obtienen y almacenan los datos en donde se buscarán los patrones. Este proceso puede ser automatizado.

*Preprocesamiento*

Se corrigen anomalías, como el ruido o los valores faltantes, con el fin de preparar los datos para su procesamiento posterior.

*Extracción*

Se identifican las características potenciales de los datos obtenidos para determinar cuáles se utilizarán en el desarrollo del modelo. Debido a que los conjuntos de datos pueden contener información redundante o irrelevante, durante el proceso de selección se buscan las características más relevantes para el problema que se pretende resolver.

### *Clasificación*

Una vez identificado el vector de características, el siguiente paso consiste en desarrollar un modelo de clasificación que permita identificar patrones en los datos. Para construir este modelo, se requieren dos tipos de datos: datos de entrenamiento (training data), utilizados para que el modelo aprenda a reconocer patrones, y datos de prueba (testing data), empleados para evaluar su desempeño.

### *Postprocesamiento*

Una vez identificados los patrones y tomadas las decisiones correspondientes, se busca validar y justificar dichas decisiones con base en los patrones encontrados. Esta etapa incluye la evaluación del grado de confianza o certeza de los resultados obtenidos.

## Ejercicio 3.18

### ¿Cuál es la diferencia entre datos de entrenamiento y datos de prueba?

La diferencia principal es que los datos de entrenamiento se utilizan para que el modelo aprenda y los datos de prueba se utilizan para evaluar qué tan bien aprendió.

| Datos de entrenamiento (Training dataset) | Datos de prueba (Test dataset) |
|---|---|
| Entrena modelos | Evalúa modelos |
| Genera resultados que se evalúan contra los resultados reales para medir identificar errores. | Compara las predicciones del modelo con resultados reales para medir su desempeño |
| Los errores ayudan a ajustar los parámetros y mejorar las predicciones del modelo. | Calcula métricas de manera exacta |
| Utiliza estos datos durante su aprendizaje | Ocupa los datos para evaluar. |