Ejercicios del capitulo 3

Ejercicio 3.1 Tipos de aprendizaje

Aprendizaje supervisado: El modelo se entrena utilizando un conjunto de datos que contiene tanto las variables de entrada como la respuesta correcta (etiqueta). El objetivo es que el modelo aprenda a mapear las entradas a las salidas para predecir nuevos casos.

Aprendizaje no supervisado: No se dispone de etiquetas. El modelo recibe únicamente los datos de entrada y debe descubrir por sí mismo estructuras o agrupaciones subyacentes, como patrones de similitud.

Aprendizaje por refuerzo: Un agente interactúa con un entorno y aprende a tomar decisiones mediante la retroalimentación de recompensas y penalizaciones. El objetivo es maximizar la recompensa acumulada a lo largo del tiempo.

Ejercicio 3.2 Técnicas centrales del aprendizaje supervisado

Clasificación: Asigna cada instancia a una categoría o clase discreta. Por ejemplo, determinar si un correo electrónico es spam o no spam.

Regresión: Predice un valor numérico continuo. Por ejemplo, estimar el precio de una vivienda a partir de sus características.

Ejercicio 3.3 Similitudes y diferencias entre aprendizaje supervisado y no supervisado

Tres similitudes:

Ambos utilizan datos para extraer conocimiento.

Ambos buscan patrones o regularidades en la información.

Ambos requieren un preprocesamiento adecuado de los datos.

Tres diferencias:

Aprendizaje supervisado	Aprendizaje no supervisado
Emplea datos etiquetados.	Emplea datos sin etiquetar.
Su objetivo es predecir una salida.	Su objetivo es agrupar o describir los datos.
La evaluación de la precisión es directa.	La evaluación es indirecta o cualitativa.

Ejercicio 3.4 Selección de técnica para un conjunto de datos

Dado que existe una variable objetivo (Health) con categorías predefinidas, se debe emplear aprendizaje supervisado, específicamente un algoritmo de clasificación. El propósito sería predecir el estado de salud de una persona a partir de su género y edad.

Ejercicio 3.5 Selección de técnica para otro conjunto de datos

Al no existir etiquetas, corresponde aplicar aprendizaje no supervisado, en particular clustering. El objetivo sería agrupar a las personas según similitudes en sus atributos (por ejemplo, rangos de edad o género), sin conocer de antemano cuántos grupos existen.

Ejercicio 3.6 Datos etiquetados y no etiquetados

Datos etiquetados (labeled): Incluyen la respuesta correcta o categoría a predecir. Por ejemplo, una imagen acompañada de la etiqueta “gato”.

Datos no etiquetados (unlabeled): Carecen de una respuesta predefinida. Por ejemplo, una imagen sin descripción.

Ejercicio 3.7: Categorización de algoritmos

Algoritmo	Categoría
Support vector machines	Supervisado
K nearest neighbors	Supervisado
K-Means	No supervisado
Q-learning	Refuerzo
Temporal difference (TD)	Refuerzo
Deep adversarial networks	Refuerzo
Hierarchical clustering	No supervisado
Principal component analysis	No supervisado
Linear regression	Supervisado
Logistic regression	Supervisado
Naive Bayes	Supervisado
t-distributed stochastic neighbor embedding (t-SNE)	No supervisado

Ejercicio 3.8: AB Testing

El AB Testing es una técnica que compara dos versiones de un elemento (A y B) para determinar cuál produce mejores resultados. Se aplica comúnmente en entornos digitales.

Planificación:

Definir el objetivo de la prueba.

Seleccionar las variables a modificar.

Establecer los posibles resultados y métricas.

Ejecutar ambas versiones simultáneamente.

Determinar la duración en función del tráfico o respuestas esperadas.

Ejemplo con los datos proporcionados:

Ejercicio 3.9: Reglas de asociación

{Milk, Eggs}→{Cheese}

Esta regla la pudimos dar por hecho porque en varias transacciones aparecen juntos leche, huevos y queso.

Ejercicio 3.10: Cálculo de soporte, confianza y lift

Soporte: Número de transacciones que contienen Milk, Eggs y Cheese dividido entre el total de transacciones.

Transacciones con los tres ítems: T1 y T10 → 2.

Soporte = 2/10=0.202/10=0.20 (20%).

Confianza: Proporción de transacciones con Milk y Eggs que también contienen Cheese.

Transacciones con Milk y Eggs: T1, T5, T10 → 3.

Con Cheese: T1, T10 → 2.

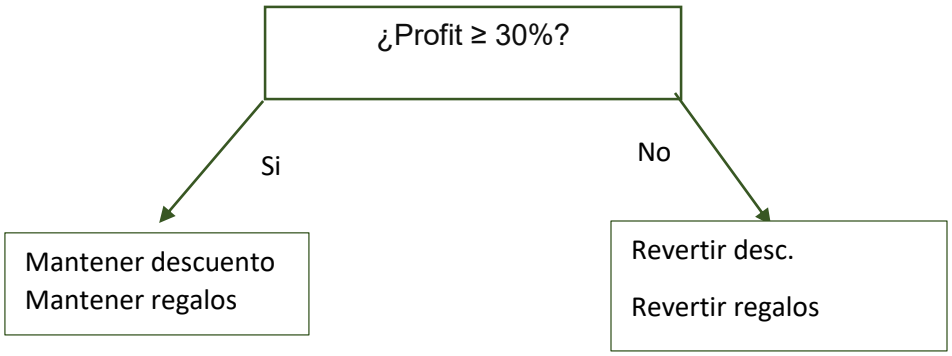
Confianza = 2/3=0.6672/3=0.667 (66.7%).

Lift: Relación entre la confianza y el soporte del consecuente.

Soporte de Cheese = 4/10=0.404/10=0.40.

Lift = 0.667/0.40=1.6670.667/0.40=1.667.Como es mayor a 1 la asociación es positiva

Ejercicio 3.11: Árbol de decisión para política de promociones



Ejercicio 3.12: Ventajas y desventajas de los árboles de decisión

Ventajas**:**

- Son fáciles de interpretar y explicar.
- Requieren pocos datos para construir un modelo inicial.
- Manejan atributos numéricos y categóricos.
- Permiten clasificación múltiple.

Desventajas**:**

- Pueden duplicar subárboles en distintas ramas.
- Pequeños cambios en los datos pueden alterar significativamente la estructura.
- Propensos al sobreajuste si el árbol es muy profundo.

Ejercicio 3.13: Enfoques para análisis de clústeres

Jerárquicos:

Aglomerativos: Cada objeto inicia como un clúster individual y se van fusionando los más similares.

Divisivos: Todos los objetos forman un solo clúster y se divide sucesivamente hasta obtener grupos individuales.

No jerárquicos:

K-Means: Se especifica el número de clústeres (K) y los objetos se asignan a los centros más cercanos, actualizando iterativamente.

Ejercicio 3.14: Técnicas de clustering jerárquico

Vecino más cercano (Single linkage): La distancia entre dos clústeres es la mínima distancia entre sus puntos.

Vecino más lejano (Complete linkage): La distancia entre dos clústeres es la máxima distancia entre sus puntos.

Promedio (Average linkage): La distancia entre dos clústeres es el promedio de todas las distancias entre pares de puntos.

Centroide: La distancia entre dos clústeres es la distancia entre sus centros (promedios).

Ejercicio 3.15: Distancia Euclidiana mínima

Datos: A(8,2), B(1,8), C(3,3), D(6,4), E(3,7), F(8,8), G(3,1), H(7,3), I(6,9), J(8,1).

Cálculo de la distancia mínima:

Entre A(8,2) y J(8,1): $d = \sqrt[2]{(8-8)^2 + (2-1)^2}$= 1

La distancia mínima es 1, entre los objetos A y J.

Ejercicio 3.16: Distancia Euclidiana máxima

Datos: A(1,1), B(6,5), C(3,3), D(3,3), E(3,1), F(5,2), G(1,8), H(1,3), I(1,9), J(4,3).

Cálculo de la distancia máxima:

Entre I(1,9) y E(3,1): $d = \sqrt[2]{68}$

Resultado: La distancia máxima es de:

$$d = \sqrt[2]{68}$$

Entre los objetos I y E

Ejercicio 3.17: Pasos del reconocimiento de patrones

Adquisición de datos: Obtención y almacenamiento de la información (sensores, registros manuales, etc.).

Preprocesamiento: Limpieza de datos, manejo de valores faltantes y reducción de ruido.

Extracción/selección de características: Identificación de los atributos más relevantes para el problema.

Clasificación: Aplicación de un modelo para asignar etiquetas o categorías a los datos.

Post-procesamiento: Validación y justificación de las decisiones tomadas por el modelo.

Ejercicio 3.18: Diferencia entre datos de entrenamiento y prueba

Datos de entrenamiento: Se utilizan para ajustar el modelo. El algoritmo aprende los patrones y relaciones a partir de ellos. Incluyen tanto las variables de entrada como la salida esperada (en aprendizaje supervisado).

Datos de prueba: Se emplean para evaluar el rendimiento del modelo con datos que no ha visto previamente. Permiten medir la capacidad de generalización.

La diferencia fundamental radica en que los primeros sirven para aprender y los segundos para evaluar. No deben coincidir, ya que de lo contrario la evaluación perdería validez.