Capítulo 3: Tecnicas Ampliamente Usadas en la Aplicacion de la Ciencia de Datos

Jose Luis Gonzalez Yerena

15 de octubre de 2026

Ejercicio 3.1

¿Cuáles son los tres tipos de machine learning? Proporcione una breve introducción de cada tipo.

1. **Aprendizaje supervisado**: El modelo se entrena utilizando un conjunto de datos etiquetado, donde cada entrada tiene una salida correspondiente. El objetivo es que el modelo aprenda a predecir la salida para nuevas entradas basándose en el conocimiento adquirido durante el entrenamiento.

2. **Aprendizaje no supervisado**: El modelo se entrena utilizando un conjunto de datos no etiquetado, donde no se proporcionan salidas correspondientes. El objetivo es descubrir patrones, estructuras o relaciones ocultas en los datos, como agrupamientos.

3. **Aprendizaje por refuerzo**: En este tipo de aprendizaje, atravez de recompesas y penalizaciones el modelo aprende a tomar decisiones mediante la interacción con un entorno. Su objetivo es maximizar la recompensa acumulada a lo largo del tiempo aprendiendo un optimo curso de accion.

Ejercicio 3.2

¿Cuáles son las dos técnicas principales del aprendizaje supervisado? Proporcione una breve introducción de cada una.

1. **Clasificacion**:Se clasifican los datos desconocidos usando aprendizaje supervisado.

2. **Regresion**:Se intenta encontrar el valor de variables dependientes atravez de las variables independiantes usando datos anteriores.

Ejercicio 3.3

¿Cuáles son las similitudes y diferencias entre el aprendizaje supervisado y el no supervisado? Mencione tres diferencias y sus similitudes.

Similitudes

1. Ambas son técnicas de aprendizaje automático que se utilizan para analizar datos y hacer predicciones.

2. Ambas técnicas requieren un conjunto de datos para entrenar el modelo.

3. Ambas buscan aprender patrones a partir de los datos y pueden utilizarse para apoyar la toma de decisiones.

Diferencias

1. En el aprendizaje supervisado se conoce el output correspondiente a cada input, para que el modelo aprenda en cada caso.

2. El aprendizaje supervisado usa datos etiquetados, mientras que el no supervisado usa datos no etiquetados.

3. El supervisado se utiliza principalmente para clasificación y regresión, y puede evaluarse comparando las predicciones con las etiquetas reales. El no supervisado se usa para encontrar grupos o estructuras (por ejemplo, mediante clustering) y su evaluación no suele tener una respuesta correcta conocida con la cual compararse.

Ejercicio 3.4

Considere los datos que se muestran a continuación. ¿Qué técnica utilizaría aprendizaje supervisado o no supervisado y por qué?

Health	**Gender**	**Age**
Healthy	Male	42
Healthy	Female	49
Healthy	Male	66
Healthy	Female	55
Healthy	Female	49
Sick	Female	31
Sick	Female	53
Sick	Female	79
Sick	Male	53
Sick	Male	31

Utilizaria aprendizaje supervisado,ya que conocemos los valores de entrada y de salida

Ejercicio 3.5

Considere los datos que se muestran a continuación. ¿Qué técnica utilizaría aprendizaje supervisado o no supervisado y por qué?

Gender	**Age**
Male	70
Female	66
Male	38
Female	40
Female	64
Male	42
Female	67
Female	72
Male	62
Male	66

Utilizaría **aprendizaje no supervisado**, ya que solo se proporcionan características de entrada (*Gender* y *Age*) y no hay una variable objetivo que se quiera predecir. Se podrían buscar patrones o grupos en los datos.

Ejercicio 3.6

Explique los términos "labeled" y "unlabeled" data. ¿Cómo puede identificar si los datos proporcionados están etiquetados o no?

Un dato **etiquetado** (*labeled*) incluye sus características de entrada y la respuesta o resultado conocido asociado a ellas, llamado etiqueta o variable objetivo. Por ejemplo, un registro con edad y género cuya etiqueta indica si la persona está sana o enferma.

Un dato **no etiquetado** (*unlabeled*) contiene características de entrada, pero no incluye la respuesta que se desea predecir. Por ejemplo, un registro con edad y género sin información sobre el estado de salud.

Para identificarlos, se revisa si los datos incluyen una columna con el resultado conocido para cada registro. Si existe esa variable objetivo, los datos están etiquetados; si solo hay características y no se conoce el resultado, no están etiquetados.

Ejercicio 3.7

Clasifique los siguientes algoritmos de aprendizaje automático en las categorías de aprendizaje supervisado, no supervisado y por refuerzo:

Algoritmo	**Supervisado**	**No supervisado**	**Por refuerzo**
Support vector machines	X		
K nearest neighbors	X		
K-Means		X	
Naive Bayes	X		
Temporal difference (TD)			X
Deep adversarial networks		X	
Hierarchical clustering		X	
Principal component analysis		X	
Linear regression	X		
Logistic regression	X		
t-distributed stochastic neighbor embedding (t-SNE)		X	

Ejercicio 3.8

¿Qué significa el término "AB Testing"? ¿Cómo se planifica este tipo de prueba? ¿Qué aplicaciones se pueden probar con esta técnica?

Significado. El *A/B testing* es un experimento controlado que compara dos versiones de un elemento: la versión A (control) y la versión B (variante). Los participantes se asignan aleatoriamente a los grupos y se mide cuál versión obtiene mejores resultados según una métrica definida.

Planificación.

1. Definir el objetivo y plantear una hipótesis comprobable.
2. Elegir la métrica de éxito, como la tasa de conversión, los clics o las ventas.
3. Decidir qué elemento cambiará entre las versiones y mantener iguales los demás factores relevantes.
4. Determinar el tamaño de muestra y la duración necesarios para obtener resultados confiables.
5. Asignar participantes aleatoriamente y ejecutar ambas versiones al mismo tiempo.
6. Analizar los resultados con una prueba estadística y decidir si se adopta la variante, se conserva el control o se requiere otra prueba.

Aplicaciones. Se puede utilizar para comparar diseños, botones y textos de sitios web o aplicaciones; asuntos de correos electrónicos; anuncios y campañas de marketing; precios, promociones o nuevas funciones de un producto.

Ejercicio 3.9

Utilice los datos de la siguiente tabla para encontrar las reglas de asociación:

TID	Items
1	Milk, Butter, Eggs, Cheese, Yoghurt
2	Butter, Eggs, Chicken, Beef, Rice
3	Chicken, Beef, Rice, Milk
4	Butter, Chicken, Jam, Honey, Ketchup
5	Oil, Olives, Milk, Eggs, Honey
6	Ketchup, Oil, Olives, Eggs, Rice
7	Yogurt, Chicken, Oil, Olives, Eggs
8	Cheese, Yoghurt, Chicken, Milk, Rice
9	Cheese, Yoghurt, Beef, Rice, Butter
10	Milk, Cheese, Eggs, Chicken, Butter

Supuestos. Como el ejercicio no especifica umbrales, se tomará un soporte mínimo de 30 % (3 de las 10 transacciones) y una confianza mínima de 70 %. "Yoghurt" y "Yogurt" se consideran el mismo artículo.

Conjuntos frecuentes. Los artículos individuales que alcanzan el soporte mínimo son Milk (5), Butter (5), Eggs (6), Cheese (4), Yogurt (4), Chicken (6), Beef (3), Rice (5), Oil (3) y Olives (3). Los pares frecuentes son:

$$\{Milk, Eggs\}, \{Milk, Cheese\}, \{Milk, Chicken\}, \{Butter, Eggs\},$$
$$\{Butter, Cheese\}, \{Butter, Chicken\}, \{Eggs, Chicken\}, \{Eggs, Oil\},$$
$$\{Eggs, Olives\}, \{Cheese, Yogurt\}, \{Chicken, Rice\}, \{Beef, Rice\},$$
$$\{Oil, Olives\}.$$

Cada uno de estos pares aparece en 3 transacciones, por lo que su soporte es 0,3. El único conjunto frecuente de tres artículos es $\{Eggs, Oil, Olives\}$, también con soporte 0,3.

Reglas de asociación con confianza de al menos 70 %**:**

No.	Regla
1	Oil $\Rightarrow$ Eggs
2	Olives $\Rightarrow$ Eggs
3	Oil $\Rightarrow$ Olives
4	Olives $\Rightarrow$ Oil
5	Beef $\Rightarrow$ Rice
6	Cheese $\Rightarrow$ Yogurt
7	Yogurt $\Rightarrow$ Cheese
8	Cheese $\Rightarrow$ Milk
9	Cheese $\Rightarrow$ Butter
10	$\{Oil, Olives\} \Rightarrow Eggs$
11	$\{Eggs, Oil\} \Rightarrow Olives$
12	$\{Eggs, Olives\} \Rightarrow Oil$
13	$Oil \Rightarrow \{Eggs, Olives\}$
14	$Olives \Rightarrow \{Eggs, Oil\}$

Ejercicio 3.10

Considere los datos del Ejercicio 3.9 y calcule el soporte, la confianza y la elevación (lift).

Fórmulas. Para una regla $X \Rightarrow Y$ y $N = 10$ transacciones:

$$\text{Soporte}(X \Rightarrow Y) = \frac{\text{frec}(X \cup Y)}{N},$$
$$\text{Confianza}(X \Rightarrow Y) = \frac{\text{Soporte}(X \cup Y)}{\text{Soporte}(X)},$$
$$\text{Lift}(X \Rightarrow Y) = \frac{\text{Confianza}(X \Rightarrow Y)}{\text{Soporte}(Y)}.$$

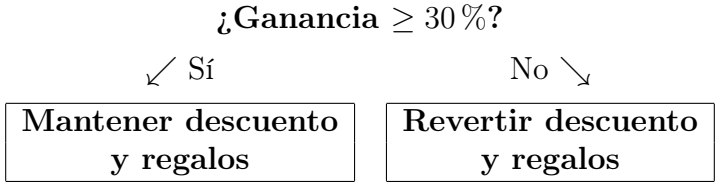
Resultados para las reglas fuertes del ejercicio 3.9:

No.	Regla	Soporte	Confianza	Lift
1	Oil ⇒ Eggs	0.3	1.00	1.67
2	Olives ⇒ Eggs	0.3	1.00	1.67
3	Oil ⇒ Olives	0.3	1.00	3.33
4	Olives ⇒ Oil	0.3	1.00	3.33
5	Beef ⇒ Rice	0.3	1.00	2.00
6	Cheese ⇒ Yogurt	0.3	0.75	1.88
7	Yogurt ⇒ Cheese	0.3	0.75	1.88
8	Cheese ⇒ Milk	0.3	0.75	1.50
9	Cheese ⇒ Butter	0.3	0.75	1.50
10	$\{Oil, Olives\} \Rightarrow Eggs$	0.3	1.00	1.67
11	$\{Eggs, Oil\} \Rightarrow Olives$	0.3	1.00	3.33
12	$\{Eggs, Olives\} \Rightarrow Oil$	0.3	1.00	3.33
13	$Oil \Rightarrow \{Eggs, Olives\}$	0.3	1.00	3.33
14	$Olives \Rightarrow \{Eggs, Oil\}$	0.3	1.00	3.33

Ejercicio 3.11

Una empresa tiene una política de promoción en la que se otorgan regalos y descuentos para aumentar las ganancias. Considere las siguientes reglas y construya un árbol de decisión:

If profit is greater than or equal to 30 %, then keep the discount.
If profit is less than 30 %, then reverse the discount.
If profit is greater than or equal to 30 %, then keep the gifts.
If profit is less than 30 %, then reverse the gifts.



Si la ganancia es al menos 30 %, se mantienen tanto el descuento como los regalos; si es menor, se revierten ambos.

Ejercicio 3.12

¿Cuáles son las ventajas y desventajas de un árbol de decisión?
Ventajas

- Son fáciles de interpretar y sus decisiones pueden expresarse como reglas.
- Requieren poca preparación de datos y pueden manejar variables numéricas y categóricas.
- Pueden representar relaciones no lineales y permiten identificar variables importantes.

Desventajas

- Un árbol demasiado profundo puede sobreajustarse a los datos de entrenamiento.
- Pueden ser inestables: pequeños cambios en los datos pueden producir árboles distintos.
- Las divisiones se eligen de forma local y no garantizan la solución global óptima; además, pueden favorecer variables con muchas categorías.

Ejercicio 3.13

¿Cuántos enfoques existen para el análisis de clústeres? Proporcione una breve introducción a cada uno.

Se suelen distinguir cinco enfoques principales:

1. **Particionamiento**: divide los datos en un número k de grupos; por ejemplo, K-Means y K-Medoids.
2. **Jerárquico**: construye una jerarquía de grupos que puede representarse mediante un dendrograma.
3. **Basado en densidad**: forma grupos en regiones densas y puede identificar ruido; por ejemplo, DBSCAN.
4. **Basado en rejilla**: divide el espacio en celdas y agrupa las celdas densas; puede ser eficiente en conjuntos grandes.
5. **Basado en modelos**: ajusta un modelo estadístico que representa la distribución de los datos, como una mezcla de distribuciones gaussianas.

Ejercicio 3.14

¿Cuántas técnicas de agrupamiento existen en el análisis de clústeres jerárquico? Proporcione una breve introducción a cada una.

El agrupamiento jerárquico tiene dos estrategias: la **aglomerativa**, que empieza con cada objeto en su propio grupo y va uniendo grupos, y la **divisiva**, que empieza con un solo grupo y lo divide progresivamente. Para decidir qué grupos unir en el método aglomerativo se usan, entre otros, estos cinco criterios:

1. **Enlace simple**: distancia mínima entre los objetos de dos grupos.
2. **Enlace completo**: distancia máxima entre los objetos de dos grupos.
3. **Enlace promedio**: promedio de las distancias entre todos los pares de objetos de ambos grupos.
4. **Enlace por centroide**: distancia entre los centroides de los grupos.
5. **Método de Ward**: une los grupos que ocasionan el menor aumento en la variación interna total.

Ejercicio 3.15

Considere los datos que se muestran a continuación y encuentre los dos objetos que tienen la distancia euclidiana mínima. Si más de dos objetos tienen la misma distancia, menciónelos todos.

	X1	**X2**
A	8	2
B	1	8
C	3	3
D	6	4
E	3	7
F	8	8
G	3	1
H	7	3
I	6	9
J	8	1

La distancia entre dos objetos es $d = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2}$. El par más cercano es A–J:

$$d(A, J) = \sqrt{(8-8)^2 + (2-1)^2} = 1.$$

Por lo tanto, **A y J** son los objetos con distancia euclidiana mínima; no hay empate.

Ejercicio 3.16

Considere los datos que se muestran a continuación y encuentre los dos objetos que tienen la distancia euclidiana máxima. Si más de dos objetos tienen la misma distancia, menciónelos todos.

	X1	**X2**
A	1	1
B	6	5
C	3	3
D	3	3
E	3	1
F	5	2
G	1	8
H	1	3
I	1	9
J	4	3

Al comparar las distancias entre los pares, la máxima se obtiene entre $I = (1, 9)$ y $E = (3, 1)$:

$$d(I, E) = \sqrt{(1-3)^2 + (9-1)^2} = \sqrt{68} \approx 8{,}25.$$

Por lo tanto, **I y E** son los objetos con distancia euclidiana máxima; no hay empate.

Ejercicio 3.17

Describa detalladamente cada paso del proceso de reconocimiento de patrones que se presenta a continuación:

- Data acquisition
- Data preprocessing
- Feature extraction/selection
- Classification
- Post-processing

1. **Adquisición de datos**: se capturan los datos del fenómeno de interés mediante sensores, cámaras, bases de datos, encuestas u otras fuentes.
2. **Preprocesamiento**: se limpian y preparan los datos, tratando valores faltantes, ruido y valores atípicos, y transformándolos a un formato adecuado.
3. **Extracción o selección de características**: se generan o eligen las variables que describen los objetos y ayudan a distinguir las clases, descartando información irrelevante o redundante.
4. **Clasificación**: un modelo entrenado utiliza las características para asignar cada objeto a una clase o categoría.
5. **Posprocesamiento**: se interpretan, validan y refinan las clasificaciones (por ejemplo, mediante umbrales o reglas adicionales) y se produce el resultado final.

Ejercicio 3.18

¿Cuál es la diferencia entre training data y test data?

Los **datos de entrenamiento** (*training data*) son los ejemplos que el modelo utiliza para aprender patrones y ajustar sus parámetros. Los **datos de prueba** (*test data*) se mantienen separados y no se usan durante el entrenamiento; sirven para evaluar cómo se desempeña el modelo con datos no vistos y qué tan bien generaliza. Evaluar el modelo con los mismos datos usados para entrenarlo puede dar una estimación demasiado optimista de su desempeño.