Capítulo 3: Tecnicas Ampliamente Usadas en la Aplicacion de la Ciencia de Datos

Jose Luis Gonzalez Yerena

16 de octubre de 2026

Ejercicio 3.1

¿Cuáles son los tres tipos de machine learning? Proporcione una breve introducción de cada tipo.

1. **Aprendizaje supervisado**: El modelo se entrena utilizando un conjunto de datos etiquetado, donde cada entrada tiene una salida correspondiente. El objetivo es que el modelo aprenda a predecir la salida para nuevas entradas basándose en el conocimiento adquirido durante el entrenamiento.

2. **Aprendizaje no supervisado**: El modelo se entrena utilizando un conjunto de datos no etiquetado, donde no se proporcionan salidas correspondientes. El objetivo es descubrir patrones, estructuras o relaciones ocultas en los datos, como agrupamientos.

3. **Aprendizaje por refuerzo**: En este tipo de aprendizaje, atravez de recompesas y penalizaciones el modelo aprende a tomar decisiones mediante la interacción con un entorno. Su objetivo es maximizar la recompensa acumulada a lo largo del tiempo aprendiendo un optimo curso de accion.

Ejercicio 3.2

¿Cuáles son las dos técnicas principales del aprendizaje supervisado? Proporcione una breve introducción de cada una.

1. **Clasificacion**:Se clasifican los datos desconocidos usando aprendizaje supervisado.

2. **Regresion**:Se intenta encontrar el valor de variables dependientes atravez de las variables independiantes usando datos anteriores.

Ejercicio 3.3

¿Cuáles son las similitudes y diferencias entre el aprendizaje supervisado y el no supervisado? Mencione tres diferencias y sus similitudes.

Similitudes

1. Ambas son técnicas de aprendizaje automático que se utilizan para analizar datos y hacer predicciones.

2. Ambas técnicas requieren un conjunto de datos para entrenar el modelo.

3. Ambas buscan aprender patrones a partir de los datos y pueden utilizarse para apoyar la toma de decisiones.

Diferencias

1. En el aprendizaje supervisado se conoce el output correspondiente a cada input, para que el modelo aprenda en cada caso.

2. El aprendizaje supervisado usa datos etiquetados, mientras que el no supervisado usa datos no etiquetados.

3. El supervisado se utiliza principalmente para clasificación y regresión, y puede evaluarse comparando las predicciones con las etiquetas reales. El no supervisado se usa para encontrar grupos o estructuras (por ejemplo, mediante clustering) y su evaluación no suele tener una respuesta correcta conocida con la cual compararse.

Ejercicio 3.4

Considere los datos que se muestran a continuación. ¿Qué técnica utilizaría aprendizaje supervisado o no supervisado y por qué?

Health	**Gender**	**Age**
Healthy	Male	42
Healthy	Female	49
Healthy	Male	66
Healthy	Female	55
Healthy	Female	49
Sick	Female	31
Sick	Female	53
Sick	Female	79
Sick	Male	53
Sick	Male	31

Utilizaria **aprendizaje supervisado**, ya que conocemos los valores de entrada y de salida

Ejercicio 3.5

Considere los datos que se muestran a continuación. ¿Qué técnica utilizaría aprendizaje supervisado o no supervisado y por qué?

Gender	**Age**
Male	70
Female	66
Male	38
Female	40
Female	64
Male	42
Female	67
Female	72
Male	62
Male	66

Utilizaría **aprendizaje no supervisado**, ya que solo dan datos de entrada (*Gender* y *Age*) y no hay una variable que se quiera predecir. Se podrían buscar patrones o grupos en los datos.

Ejercicio 3.6

Explique los términos "labeled" y "unlabeled" data. ¿Cómo puede identificar si los datos proporcionados están etiquetados o no?

Un dato **etiquetado** incluye características de entrada y el resultado asociado a ellas, llamado etiqueta o variable objetivo.

Un dato **no etiquetado** contiene características de entrada, pero no la respuesta que se desea predecir.

Para identificarlos, se busca si los datos tienen una columna con el resultado para cada registro. Si existe la variable objetivo, son datos etiquetados, si solo hay características no están etiquetados.

Ejercicio 3.7

Clasifique los siguientes algoritmos de aprendizaje automático en las categorías de aprendizaje supervisado, no supervisado y por refuerzo:

Algoritmo	**Supervisado**	**No supervisado**	**Por refuerzo**
Support vector machines	X		
K nearest neighbors	X		
K-Means		X	
Naive Bayes	X		
Temporal difference (TD)			X
Deep adversarial networks		X	
Hierarchical clustering		X	
Principal component analysis		X	
Linear regression	X		
Logistic regression	X		
t-distributed stochastic neighbor embedding (t-SNE)		X	

Ejercicio 3.8

¿Qué significa el término "AB Testing"? ¿Cómo se planifica este tipo de prueba? ¿Qué aplicaciones se pueden probar con esta técnica?

Es un test controlado que compara dos versiones: la versión A (control) y la versión B (variante).Se asignan aleatoriamente a los grupos y se busca encontrar que versión tiene mejores resultados según alguna métrica dada.

Planificación.

1. Definir un objetivo
2. Elegir la métrica de éxito
3. Decidir qué cambiará entre versiones y mantener iguales demás factores
4. Determinar el tamaño de muestra y la duración para obtener resultados confiables.

Aplicaciones. Se suele usar para comparar diseños y textos de sitios web o aplicaciones; anuncios y campañas de marketing; etc.

Ejercicio 3.9

Utilice los datos de la siguiente tabla para encontrar las reglas de asociación:

TID	**Items**
1	Milk, Butter, Eggs, Cheese, Yoghurt
2	Butter, Eggs, Chicken, Beef, Rice
3	Chicken, Beef, Rice, Milk
4	Butter, Chicken, Jam, Honey, Ketchup
5	Oil, Olives, Milk, Eggs, Honey
6	Ketchup, Oil, Olives, Eggs, Rice
7	Yogurt, Chicken, Oil, Olives, Eggs
8	Cheese, Yoghurt, Chicken, Milk, Rice
9	Cheese, Yoghurt, Beef, Rice, Butter
10	Milk, Cheese, Eggs, Chicken, Butter

Objetos individuales que alcanzan el soporte mínimo son Milk (5), Butter (5), Eggs (6), Cheese (4), Yogurt (4), Chicken (6), Beef (3), Rice (5), Oil (3) y Olives (3). Los pares frecuentes son:

$$\{Milk, Eggs\}, \{Milk, Cheese\}, \{Milk, Chicken\}, \{Butter, Eggs\},$$
$$\{Butter, Cheese\}, \{Butter, Chicken\}, \{Eggs, Chicken\}, \{Eggs, Oil\},$$
$$\{Eggs, Olives\}, \{Cheese, Yogurt\}, \{Chicken, Rice\}, \{Beef, Rice\},$$
$$\{Oil, Olives\}.$$

Reglas de asociación con confianza de al menos 70 %**:**

No.	**Regla**
1	Oil $\Rightarrow$ Eggs
2	Olives $\Rightarrow$ Eggs
3	Oil $\Rightarrow$ Olives
4	Olives $\Rightarrow$ Oil
5	Beef $\Rightarrow$ Rice
6	Cheese $\Rightarrow$ Yogurt
7	Yogurt $\Rightarrow$ Cheese
8	Cheese $\Rightarrow$ Milk
9	Cheese $\Rightarrow$ Butter
10	$\{Oil, Olives\} \Rightarrow Eggs$
11	$\{Eggs, Oil\} \Rightarrow Olives$
12	$\{Eggs, Olives\} \Rightarrow Oil$
13	$Oil \Rightarrow \{Eggs, Olives\}$
14	$Olives \Rightarrow \{Eggs, Oil\}$

Ejercicio 3.10

Considere los datos del Ejercicio 3.9 y calcule el soporte, la confianza y la elevación (lift).

Fórmulas. Para una regla $X \Rightarrow Y$ y $N = 10$ transacciones:

$$\text{Soporte}(X \Rightarrow Y) = \frac{\text{n}(X \cap Y)}{N},$$
$$\text{Confianza}(X \Rightarrow Y) = \frac{\text{n}(X \cap Y)}{\text{n}(X)},$$
$$\text{Lift}(X \Rightarrow Y) = \frac{\text{Confianza}(X \Rightarrow Y)}{\text{n}(Y)}.$$

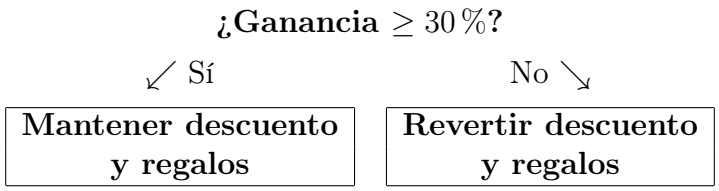
Resultados para las reglas fuertes del ejercicio 3.9:

No.	Regla	Soporte	Confianza	Lift
1	Oil ⇒ Eggs	0.3	1.00	1.67
2	Olives ⇒ Eggs	0.3	1.00	1.67
3	Oil ⇒ Olives	0.3	1.00	3.33
4	Olives ⇒ Oil	0.3	1.00	3.33
5	Beef ⇒ Rice	0.3	1.00	2.00
6	Cheese ⇒ Yogurt	0.3	0.75	1.88
7	Yogurt ⇒ Cheese	0.3	0.75	1.88
8	Cheese ⇒ Milk	0.3	0.75	1.50
9	Cheese ⇒ Butter	0.3	0.75	1.50
10	$\{Oil, Olives\} \Rightarrow Eggs$	0.3	1.00	1.67
11	$\{Eggs, Oil\} \Rightarrow Olives$	0.3	1.00	3.33
12	$\{Eggs, Olives\} \Rightarrow Oil$	0.3	1.00	3.33
13	$Oil \Rightarrow \{Eggs, Olives\}$	0.3	1.00	3.33
14	$Olives \Rightarrow \{Eggs, Oil\}$	0.3	1.00	3.33

Ejercicio 3.11

Una empresa tiene una política de promoción en la que se otorgan regalos y descuentos para aumentar las ganancias. Considere las siguientes reglas y construya un árbol de decisión:

If profit is greater than or equal to 30 %, then keep the discount.
If profit is less than 30 %, then reverse the discount.
If profit is greater than or equal to 30 %, then keep the gifts.
If profit is less than 30 %, then reverse the gifts.



Ejercicio 3.12

¿Cuáles son las ventajas y desventajas de un árbol de decisión?
Ventajas

- Fáciles de interpretar y sus decisiones pueden usarse como reglas.
- Poca preparación de datos y pueden manejar valores numéricos y categóricos.
- Pueden representar relaciones no lineales.

Desventajas

- Pequeños cambios en los datos pueden producir árboles distintos.
- Las divisiones se eligen localmente y no garantizan la mejor solución global.

Ejercicio 3.13

¿Cuántos enfoques existen para el análisis de clústeres? Proporcione una breve introducción a cada uno.

1. **Jerárquico**: Construye una estructura de grupos anidados.
2. **No jerárquico**: Busca una partición de los datos en grupos, sin construir esa jerarquía.

Dentro del enfoque jerárquico hay dos estrategias:

- **Aglomerativa**: Empieza con cada objeto separado y fusiona grupos.
- **Divisiva**: Empieza con todos los objetos juntos y divide grupos.

Ejercicio 3.14

¿Cuántas técnicas de agrupamiento existen en el análisis de clústeres jerárquico? Proporcione una breve introducción a cada una.

1. **Enlace simple**: Distancia mínima entre los objetos de dos grupos.
2. **Enlace completo**: Distancia máxima entre los objetos de dos grupos.
3. **Enlace promedio**: Promedio de las distancias entre todos los pares de objetos de ambos grupos.
4. **Enlace por centroide**: Distancia entre los centroides de los grupos.

Ejercicio 3.15

Considere los datos que se muestran a continuación y encuentre los dos objetos que tienen la distancia euclidiana mínima.

	X1	**X2**
A	8	2
B	1	8
C	3	3
D	6	4
E	3	7
F	8	8
G	3	1
H	7	3
I	6	9
J	8	1

La distancia entre dos objetos es $d = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$.

$$d(A, J) = \sqrt{(8-8)^2 + (2-1)^2} = 1.$$

La distancia máxima se obtiene entre $A = (8, 2)$ y $J = (8, 1)$:

Ejercicio 3.16

Considere los datos que se muestran a continuación y encuentre los dos objetos que tienen la distancia euclidiana máxima.

	X1	**X2**
A	1	1
B	6	5
C	3	3
D	3	3
E	3	1
F	5	2
G	1	8
H	1	3
I	1	9
J	4	3

La distancia máxima se obtiene entre $I = (1, 9)$ y $E = (3, 1)$:

$$d(I, E) = \sqrt{(1-3)^2 + (9-1)^2} = \sqrt{68} \approx 8{,}25.$$

Ejercicio 3.17

Describa detalladamente cada paso del proceso de reconocimiento de patrones que se presenta a continuación:

- Data acquisition
- Data preprocessing
- Feature extraction/selection
- Classification
- Post-processing

1. **Adquisición de datos**: se obtienen los datos atravez de sensores, cámaras, bases de datos, encuestas u otras fuentes.
2. **Preprocesamiento**: se limpian y preparan los datos, tratando valores faltantes, ruido y valores atípicos, y transformándolos a un formato adecuado.
3. **Extracción o selección de características**: se generan o eligen las variables que describen los objetos y ayudan a distinguir las clases
4. **Clasificación**: un modelo entrenado utiliza las características para asignar cada objeto a una clase o categoría.
5. **Posprocesamiento**: se interpretan, validan y refinan las clasificaciones (por ejemplo, mediante umbrales o reglas adicionales) y se produce el resultado final.

Ejercicio 3.18

¿Cuál es la diferencia entre training data y test data?

Los (*training data*) son los ejemplos que el modelo utiliza para aprender patrones y ajustar sus parámetros. Los (*test data*) se mantienen separados y no se usan durante el entrenamiento del modelo. Sirven para evaluar cómo se comporta el modelo con datos no vistos. Si se evalúa el modelo con los mismos datos usados para entrenarlo puede dar una estimación muy optimista.